

Ensamblaje de fragmentos de ADN

Informe del laboratorio 03a

Autor Gino Sebastian

Curso Biología Molecular Computacional CB309

Docente Yván Jesús Túpac Valdivia

Universidad Universidad Católica San Pablo

Fecha 19 de septiembre de 2026

Se desarrollaron dos programas independientes en C++ para ensamblar los ocho fragmentos del enunciado y buscar un camino hamiltoniano. Se obtuvo una secuencia de **55 bases**, que coincide con la longitud objetivo, y una secuencia más corta de **50 bases**. En ambas se verificó la presencia exacta de los ocho fragmentos, usando la orientación directa o su complemento reverso.

Objetivos y datos de entrada

El trabajo resuelve la secuencia de consenso sin errores, la elección de una longitud cercana a $l = 55$ y la búsqueda de enlaces con un umbral t . También presenta los fragmentos alineados, un subgrafo acíclico y mediciones al variar la cantidad y longitud de las cadenas.

Fragmento	Secuencia original	Bases
f1	ATCCGTTGAAGCCGCGGGC	19
f2	TTAACTCGAGG	11
f3	TTAAGTACTGCCCG	14
f4	ATCTGTGTCGGG	12
f5	CGACTCCCGACACA	14
f6	CACAGATCCGTTGAAGCCGCGGG	23
f7	CTCGAGTTAAGTA	13
f8	CGCGGGCAGTACTT	14

Repositorio y archivos

Repositorio: <https://github.com/GinoSebastianD/Molecular>

Carpeta del trabajo: **lab03a-ensamblaje**.

Los archivos **codigos/01_consenso.cpp** y **codigos/02_hamiltoniano.cpp** se compilan por separado. La carpeta incluye las entradas, las capturas, los registros de ejecución y este informe. El código usa funciones, cadenas, vectores, bucles y recursión; no contiene comentarios.

1 Método de ensamblaje

Ensamblaje sin errores

Un solapamiento de k bases existe cuando el sufijo de una cadena coincide exactamente con el prefijo de otra. Para unir las se agrega solamente la parte que no coincide. Por ejemplo, AAAC y ACGT tienen un solapamiento de 2 bases y producen AAACGT.

Para obtener el complemento reverso se invierte la cadena y se cambia A por T, T por A, C por G y G por C. Así, el complemento reverso de AAAAC es GTTTT. El signo + representa la cadena original y el signo - su complemento reverso. Esta consideración de ambas hebras coincide con el modelo de grafos de ensamblaje descrito por Simpson y Durbin [2].

Programa de consenso

La función buscar prueba cada fragmento pendiente en las dos orientaciones. Si ya está contenido en la cadena construida, lo marca como utilizado. En otro caso, prueba **todos los solapamientos positivos** que coinciden, incluidos los que no son máximos. Cada llamada recursiva agrega un fragmento y después permite volver atrás para probar otra opción.

Al completar los fragmentos, guarda la cadena más corta y la que minimiza $|longitud - l|$. Si hay empate en esa distancia, prefiere la cadena más corta; si también empata su longitud, prefiere el mayor enlace mínimo de construcción. Una rama se descarta cuando su longitud supera l más la mejor diferencia conocida, porque las siguientes uniones no pueden acortarla.


Entrada y alcance de los programas

La primera línea de entrada de consenso contiene n y l . La de hamiltoniano contiene n , l y t . Después se escriben las n cadenas, una por línea. Los programas aceptan de 1 a 10 fragmentos con las letras A, C, G y T en mayúsculas. El procedimiento de consenso busca ensamblajes conectados sin huecos; informa si no existe una solución con solapamientos positivos.

2 Compilación con Visual Studio 2026

Se utilizó **Visual Studio Community 2026, versión 18.8.3**, instalado en el equipo, con el compilador **MSVC 19.51.36252 para x64**. La solución contiene dos proyectos independientes, Consenso y Hamiltoniano, en configuración Release x64, con optimización y nivel de advertencias 3. El código es compatible con C++11; el proyecto selecciona C++14, la opción más antigua disponible en MSVC.

Se recompiló la solución desde Visual Studio y desde CMD mediante MSBuild. El entorno de Visual Studio informó **2 proyectos correctos y 0 con errores**; la compilación de CMD finalizó con **0 advertencias, 0 errores y código de salida 0**. El registro del entorno se conserva en resultados/visual_studio/compilacion_ide.txt y el de MSBuild en compilacion.log.



```
Lab03a - Compilacion - Visual x + v
VISUAL STUDIO COMMUNITY 2026 - COMPILACION C++
Gino Sebastian - Laboratorio 03a

Compilador de Microsoft instalado con Visual Studio 2026
Microsoft (R) C/C++ Optimizing Compiler Version 19.51.36252 for x64
(C) Microsoft Corporation. Todos los derechos reservados.

uso : cl [ opción... ] nombre de archivo... [ /link opción de vínculo... ]

MSBuild visual_studio\EnsamblajeADN.sln /t:Rebuild /p:Configuration=Release /p:Platform=x64

01_consenso.cpp
Consenso.vcxproj -> C:\Users\ginod\OneDrive\Documentos\ChatGPT\Molecular\lab03a-ensamblaje\
build\vs2026\Relea
se\consenso.exe
02_hamiltoniano.cpp
Hamiltoniano.vcxproj -> C:\Users\ginod\OneDrive\Documentos\ChatGPT\Molecular\lab03a-ensambl
aje\build\vs2026\R
elease\hamiltoniano.exe

Compilación correcta.
0 Advertencia(s)
0 Errores

FileLogger wrote to: C:\Users\ginod\OneDrive\Documentos\ChatGPT\Molecular\lab03a-ensamblaje\r
esultados\visual_studio\compilacion.log

Tiempo transcurrido 00:00:04.69

Codigo de salida de MSBuild: 0

Presione una tecla para continuar . . .
```

Figura 1. Captura real de CMD con el compilador instalado con Visual Studio 2026 y la compilación correcta de los dos programas.

Cómo repetir la ejecución

Abrir visual_studio/EnsamblajeADN.sln, elegir Release y x64, y seleccionar Compilar > Recompilar solución. También se puede ejecutar visual_studio/compilar.cmd. Los archivos ejecutar_consenso.cmd y ejecutar_hamiltoniano_t2.cmd, t7.cmd y t8.cmd ejecutan los programas con las entradas incluidas.

Las imágenes de consola son capturas reales de CMD, alojado en Windows Terminal. Las salidas guardadas se mostraron con el comando type para mantenerlas completas y legibles; solo se omitieron líneas vacías. El consenso aparece en dos vistas del mismo registro. Las mediciones y pruebas son resúmenes de ejecuciones reales de los archivos compilados con MSVC.

3 Secuencias de consenso obtenidas

Con $l = 55$, el primer programa obtiene una diferencia de 0 bases. Las posiciones de las capturas empiezan en 1 y permiten comprobar dónde aparece cada fragmento. Los guiones indican espacio de alineación, no bases añadidas al ADN.

```
Lab03a - Captura consenso55 x + v
VISUAL STUDIO 2026 - GINO SEBASTIAN - LABORATORIO 03A
Salida real guardada del ejecutable C++ - consenso55

CONSENSO SIN ERRORES
Fragmentos: 8
Longitud objetivo: 55 bases
Orientaciones: + directa, - complemento reverso
CONSENSO MAS CERCANO AL OBJETIVO
GCCCGCGGCTTCAACGGATCTGTGTCGGGAGTCGCGGGCAGTACTTAACTCGAGG
Longitud: 55 bases
f1- GCCCGCGGCTTCAACGGAT----- [1, 19]
f2+ -----TTAACTCGAGG [45, 55]
f3- -----CGGGCAGTACTTAA----- [35, 48]
f4+ -----ATCTGTGTCGGG----- [18, 29]
f5- -----TGTGTCGGGAGTCG----- [21, 34]
f6- -CCCGCGGCTTCAACGGATCTGTG----- [2, 24]
f7- -----TACTTAACTCGAG- [42, 54]
f8+ -----CGCGGGCAGTACTT----- [33, 46]
Verificacion exacta: 8/8 fragmentos
Diferencia con el objetivo: 0 bases
Menor enlace de la construccion elegida: 2 bases

Presione una tecla para continuar . . .
```

Figura 2. Consenso de 55 bases y coincidencia exacta de los ocho fragmentos.

```
Lab03a - Captura consenso50 x + v
VISUAL STUDIO 2026 - GINO SEBASTIAN - LABORATORIO 03A
Salida real guardada del ejecutable C++ - consenso50

CONSENSO MAS CORTO
CCTCGAGTTAAGTACTGCCCGCGGCTTCAACGGATCTGTGTCGGGAGTCG
Longitud: 50 bases
f1- -----GCCCGCGGCTTCAACGGAT----- [17, 35]
f2- CCTCGAGTTAA----- [1, 11]
f3+ -----TTAAGTACTGCCCG----- [8, 21]
f4+ -----ATCTGTGTCGGG----- [34, 45]
f5- -----TGTGTCGGGAGTCG [37, 50]
f6- -----CCCGCGGCTTCAACGGATCTGTG----- [18, 40]
f7+ -CTCGAGTTAAGTA----- [2, 14]
f8- -----AAGTACTGCCCGCG----- [10, 23]
Verificacion exacta: 8/8 fragmentos
Estados visitados: 16374
Construcciones completas evaluadas: 1604
Tiempo de busqueda: 50.050 ms

Presione una tecla para continuar . . .
```

Figura 3. Consenso más corto, de 50 bases, y estadísticas de la misma búsqueda.

La búsqueda visitó 16 374 estados y evaluó 1 604 construcciones completas. Estas construcciones pueden repetir una misma cadena; no representan 1 604 consensos distintos. La longitud mínima encontrada fue 50, mientras que el objetivo de 55 seleccionó una construcción con enlace mínimo de 2 bases.

4 Camino hamiltoniano con linkage

El segundo programa calcula el solapamiento máximo entre cada par de fragmentos orientados. Conserva una arista dirigida cuando el solapamiento es al menos t . La matriz usa 16 vértices orientados, pero la búsqueda marca el fragmento original como visitado: se elige **una sola orientación de cada uno de los ocho fragmentos**. Por tanto, el camino visita los ocho fragmentos, no los 16 vértices orientados.

La búsqueda recursiva prueba los enlaces disponibles sin repetir fragmentos. Entre los caminos completos escoge el ensamblaje más cercano a l ; si empatan, el más corto. Para el consenso de 55 bases se fija $t = 2$, porque ese es el enlace mínimo observado en su construcción.

```
Lab03a - Captura hamiltonian x + v
VISUAL STUDIO 2026 - GINO SEBASTIAN - LABORATORIO 03A
Salida real guardada del ejecutable C++ - hamiltoniano_t2

CAMINO HAMILTONIANO
Fragmentos: 8
Longitud objetivo: 55 bases
Linkage t: 2
Vertices orientados: 16
Aristas: 40
Caminos completos: 20
Camino: f1- -[18]-> f6- -[7]-> f4+ -[9]-> f5- -[2]-> f8+ -[12]-> f3- -[7]-> f7- -[10]-> f2+
SECUENCIAS ENLAZADAS
f1- GCCCGCGGCTTCAACGGAT----- [1, 19]
f6- -CCCGCGGCTTCAACGGATCTGTG----- [2, 24]
f4+ -----ATCTGTGTCGGG----- [18, 29]
f5- -----TGTGTCGGGAGTCG----- [21, 34]
f8+ -----CGCGGGCAGTACTT----- [33, 46]
f3- -----CGGGCAGTACTTAA----- [35, 48]
f7- -----TACTTAACTCGAG----- [42, 54]
f2+ -----TTAACTCGAGG----- [45, 55]
ADN GCCCGCGGCTTCAACGGATCTGTGTCGGGAGTCGCGGGCAGTACTTAACTCGAGG
Longitud: 55 bases
Diferencia con el objetivo: 0 bases
Verificacion exacta: 8/8 fragmentos
Estados visitados: 967
Tiempo de grafo y busqueda: 0.231 ms
Grafo guardado en grafo.dot

Presione una tecla para continuar . . .
```

Figura 4. Salida con $t = 2$: camino, pesos, fragmentos enlazados y cadena resultante, mostrada en CMD.

La suma de las longitudes originales es 120. Los enlaces del camino suman $18 + 7 + 9 + 2 + 12 + 7 + 10 = 65$. Por ello, la longitud ensamblada es **$120 - 65 = 55$ bases**. Se evaluaron 20 caminos completos; el conteo incluye las orientaciones complementarias equivalentes.


Cada arista usa el solapamiento máximo de su par, a diferencia del primer programa, que también prueba solapamientos menores. Ambas búsquedas coinciden en la solución de 55 bases para los datos del laboratorio.

5 Visualización del subgrafo acíclico

El grafo completo de $t = 2$ tiene 16 vértices orientados y 40 aristas. La figura muestra el subgrafo inducido por las ocho orientaciones elegidas: conserva 14 aristas. El camino hamiltoniano aparece en azul; los otros siete enlaces aparecen en gris.

Subgrafo con las ocho orientaciones elegidas

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian



Umbral $t = 2$ · 8 vértices · 14 aristas · Pesos expresados en bases coincidentes

Generado a partir de grafo.dot. Todas las aristas avanzan de izquierda a derecha; este subgrafo es acíclico. El grafo completo conserva ambas orientaciones: 16 vértices y 40 aristas.

Figura 5. Subgrafo obtenido del archivo grafo.dot, con pesos en bases coincidentes.

En esta disposición todas las aristas avanzan de izquierda a derecha, lo que demuestra que el subgrafo mostrado es acíclico. El camino azul recorre cada fragmento una vez. El grafo completo con ambas orientaciones puede contener ciclos; la figura no afirma que ese grafo completo sea acíclico.

Elección del umbral y sensibilidad del resultado

El valor $t = 2$ permite recuperar la longitud solicitada, pero acepta un enlace corto entre $f5-$ y $f8+$. Al elevar el umbral a 7, solo quedan 14 aristas orientadas y dos caminos completos, correspondientes a una cadena de 50 bases y su complemento reverso. Con $t = 8$ quedan 8 aristas y desaparecen los caminos completos.

Umbral t	Aristas	Caminos	Longitud obtenida	Diferencia con 55
2	40	20	55 bases	0 bases
7	14	2	50 bases	5 bases
8	8	0	Sin camino	No corresponde

Para $t = 7$, los pesos son 10, 7, 12, 7, 18, 7 y 9. Suman 70, de modo que $120 - 70 = 50$. El mayor umbral que conserva un camino en estos datos es 7: si con 8 no existe, tampoco existirá con valores superiores, que solo eliminan más aristas.

Acercarse a 55 bases responde al criterio de longitud del enunciado. El ensamblaje de 50 bases tiene enlaces mínimos más largos. Las coincidencias exactas verifican compatibilidad con las lecturas, pero los datos no permiten afirmar una única reconstrucción biológica verdadera.

6 Evidencia de los umbrales de enlace

Las siguientes capturas corresponden a ejecuciones independientes del programa hamiltoniano con los mismos ocho fragmentos y $l = 55$. En el caso $t = 7$ se muestran el camino y el alineamiento completos. El caso $t = 8$ informa correctamente que no existe camino.

```
Lab03a - Captura hamiltonian x + v
VISUAL STUDIO 2026 - GINO SEBASTIAN - LABORATORIO 03A
Salida real guardada del ejecutable C++ - hamiltoniano_t7

CAMINO HAMILTONIANO
Fragmentos: 8
Longitud objetivo: 55 bases
Linkage t: 7
Vertices orientados: 16
Aristas: 14
Caminos completos: 2
Camino: f2- -[10]-> f7+ -[7]-> f3+ -[12]-> f8- -[7]-> f1- -[18]-> f6- -[7]-> f4+ -[9]-> f5-
SECUENCIAS ENLAZADAS
f2- CCTCGAGTTAA----- [1, 11]
f7+ -CTCGAGTTAAGTA----- [2, 14]
f3+ -----TTAAGTACTGCCCG----- [8, 21]
f8- -----AAGTACTGCCCGCG----- [10, 23]
f1- -----GCCCGCGGCTTCAACGGAT----- [17, 35]
f6- -----CCCGCGGCTTCAACGGATCTGTG----- [18, 40]
f4+ -----ATCTGTGTCGGG----- [34, 45]
f5- -----TGTGTCGGGAGTCG [37, 50]
ADN CCTCGAGTTAAGTACTGCCCGCGGCTTCAACGGATCTGTGTCGGGAGTCG
Longitud: 50 bases
Diferencia con el objetivo: 5 bases
Verificacion exacta: 8/8 fragmentos
Estados visitados: 73
Tiempo de grafo y busqueda: 0.161 ms
Grafo guardado en grafo.dot

Presione una tecla para continuar . . .
```

Figura 6. Camino de 50 bases con $t = 7$ y coincidencia exacta de los ocho fragmentos.

```
Lab03a - Captura hamiltonian x + v
VISUAL STUDIO 2026 - GINO SEBASTIAN - LABORATORIO 03A
Salida real guardada del ejecutable C++ - hamiltoniano_t8

CAMINO HAMILTONIANO
Fragmentos: 8
Longitud objetivo: 55 bases
Linkage t: 8
Vertices orientados: 16
Aristas: 8
Caminos completos: 0
No existe camino hamiltoniano para este valor de t.
Estados visitados: 25
Tiempo de grafo y busqueda: 0.137 ms
Grafo guardado en grafo.dot

Presione una tecla para continuar . . .
```

Figura 7. Ausencia de camino al exigir al menos 8 bases por enlace.

7 Comportamiento computacional con MSVC

Se realizaron tres ejecuciones por caso y se tomó la mediana en milisegundos. El tiempo del primer programa mide la búsqueda; el del segundo incluye la construcción de la matriz de solapamientos y la búsqueda. Se excluyen la lectura de entrada, la escritura de resultados y el inicio del proceso.

Para variar n se usaron 4, 6 y 8 fragmentos de 12 bases, extraídos cada 4 posiciones de una misma cadena generada con semilla 309; se invirtió la orientación de los fragmentos alternos. El objetivo fue $12 + 4(n - 1)$, y el grafo usó $t = 4$. Las entradas concretas se incluyen en datos/prueba_n*.

Para variar la longitud se repitió cada base del conjunto original 1, 2 y 4 veces. Se multiplicaron l y t por el mismo factor. Esto es un experimento sintético reproducible: puede introducir solapamientos adicionales y no representa nuevas lecturas biológicas.

```
Lab03a - Captura rendimiento x + v
VISUAL STUDIO 2026 - GINO SEBASTIAN - LABORATORIO 03A
Salida real guardada del ejecutable C++ - rendimiento

COMPORTAMIENTO COMPUTACIONAL
Mediana de 3 ejecuciones por caso, en milisegundos.
Caso      Programa      n      L      Estados  Mediana ms
n4_L12    consenso      4      12      146      0.121
n4_L12    hamiltoniano  4      12      47       0.026
n6_L12    consenso      6      12     1602     1.747
n6_L12    hamiltoniano  6      12     123      0.063
n8_L12    consenso      8      12    21260    24.159
n8_L12    hamiltoniano  8      12     327      0.126
oficial_x1 consenso      8    11-23   16374    52.437
oficial_x1 hamiltoniano  8    11-23    967     0.234
oficial_x2 consenso      8    22-46   33511   290.091
oficial_x2 hamiltoniano  8    22-46    967     0.646
oficial_x4 consenso      8    44-92  102838  2198.483
oficial_x4 hamiltoniano  8    44-92    967     2.148

Presione una tecla para continuar . . .
```

Figura 8. Registro de mediciones mostrado en CMD: medianas de tres ejecuciones y estados visitados. L indica la longitud de los fragmentos o su intervalo.

Con longitud fija de 12 bases, pasar de 4 a 8 fragmentos aumentó los estados del consenso de 146 a 21 260 y la mediana de 0,121 a 24,159 ms. Para el conjunto original ampliado cuatro veces, el consenso visitó 102 838 estados y tardó 2 198,483 ms; con tamaño original visitó 16 374 y tardó 52,437 ms.

El grafo de los casos escalados conservó 967 estados. Sus tiempos fueron menores porque calcula una vez los enlaces y filtra los recorridos con t . La diferencia no es una comparación de algoritmos equivalentes: el consenso explora más tamaños de solapamiento y aplica una poda distinta. Las duraciones cercanas a un milisegundo pueden variar por la carga del equipo; el número de estados es más estable.

8 Complejidad y verificación


Complejidad del programa de consenso

Sean n el número de fragmentos y L su longitud máxima. Hay $n!$ órdenes y hasta 2^n elecciones de orientación. Además, el programa puede probar hasta L tamaños de solapamiento en cada unión. Si N es el número de estados visitados, una cota conservadora del tiempo es $O(N n^2 L^2)$, y N está acotado por $O(n! (2L)^n)$. La memoria auxiliar es $O(n^2 L)$, por las cadenas parciales conservadas en la recursión. La poda reduce el trabajo observado, pero no elimina el crecimiento combinatorio del peor caso.

Complejidad del grafo

La función solapamiento prueba hasta L longitudes y compara subcadenas de hasta L bases. Construir la matriz cuesta $O(n^2 L^2)$. La búsqueda puede explorar $n!$ órdenes y 2^n orientaciones; una cota conservadora de tiempo total es $O(n^2 L^2 + n \cdot n! \cdot 2^n)$. La memoria auxiliar es $O(n^2 + nL)$, por la matriz, las cadenas y los vectores del recorrido.

El parámetro t reduce la cantidad de aristas y estados en la práctica. Ninguno de los programas pretende procesar un genoma completo: se trata de búsquedas exhaustivas sencillas para conjuntos pequeños. El límite de entrada de 10 fragmentos evita tamaños accidentales, pero no garantiza una ejecución rápida para cualquier entrada aceptada.



```
Lab03a - Captura pruebas - Vi
VISUAL STUDIO 2026 - GINO SEBASTIAN - LABORATORIO 03A
Salida real guardada del ejecutable C++ - pruebas

PRUEBAS DE FUNCIONAMIENTO
01. OK Consenso oficial de 55 bases
02. OK Hamiltoniano t2 y enlace de 2 bases
03. OK Hamiltoniano t7 y consenso de 50 bases
04. OK Hamiltoniano t8 sin camino
05. OK Solapamiento no maximo para alcanzar l
06. OK Fragmento contenido
07. OK Uso obligatorio del complemento reverso
08. OK Uso obligatorio del complemento reverso en grafo
09. OK Sin solapamientos entre fragmentos
10. OK Un fragmento
11. OK Letra de ADN invalida
12. OK Umbral invalido
Resultado: 12/12 pruebas correctas.

Presione una tecla para continuar . . . |
```

Figura 9. Registro real de las 12 pruebas realizadas sobre los programas compilados con Visual Studio 2026, mostrado en CMD.

Además de comprobar las salidas esperadas, se verificó por separado que cada fragmento, o su complemento reverso, fuera una subcadena exacta de los consensos oficiales. También se revisaron las coordenadas impresas. El caso AAAA y AAAC, con $l = 7$, confirmó que el consenso prueba solapamientos no máximos: obtiene 7 bases, aunque el consenso más corto tiene 5.

9 Conclusiones y referencias

Los dos códigos resuelven por separado los apartados del laboratorio. El consenso seleccionado alcanza exactamente 55 bases y contiene las ocho lecturas sin errores. El camino con $t = 2$ reproduce ese resultado y permite visualizar sus enlaces. El análisis de $t = 7$ y $t = 8$ muestra cómo un umbral mayor puede llevar a una secuencia más corta o impedir el recorrido. Las pruebas de escala evidencian que la búsqueda crece con el número de fragmentos y con las alternativas de solapamiento.

Referencias

- [1] Túpac Valdivia, Y. J. (2026). Laboratorio 03a Ensamblaje de Fragmentos de ADN. Biología Molecular Computacional CB309, Universidad Católica San Pablo. Enunciado proporcionado, 16 de septiembre de 2026, pp. 1-2.
- [2] Simpson, J. T., y Durbin, R. (2010). Efficient construction of an assembly string graph using the FM-index. *Bioinformatics*, 26(12), i367-i373. <https://pmc.ncbi.nlm.nih.gov/articles/PMC2881401/>. Se utiliza para el concepto de solapamiento entre hebras opuestas.