

# Ensamblaje de fragmentos de ADN

## Informe del laboratorio 03a

**Autor** Gino Sebastian

**Curso** Biología Molecular Computacional CB309

**Docente** Yván Jesús Túpac Valdivia

**Universidad** Universidad Católica San Pablo

**Fecha** 19 de septiembre de 2026

Se desarrollaron dos programas independientes en C++ para ensamblar los ocho fragmentos del enunciado y buscar un camino hamiltoniano. Se obtuvo una secuencia de **55 bases**, que coincide con la longitud objetivo, y una secuencia más corta de **50 bases**. En ambas se verificó la presencia exacta de los ocho fragmentos, usando la orientación directa o su complemento reverso.

### Objetivos y datos de entrada

El trabajo resuelve la secuencia de consenso sin errores, la elección de una longitud cercana a  $l = 55$  y la búsqueda de enlaces con un umbral  $t$ . También presenta los fragmentos alineados, un subgrafo acíclico y mediciones al variar la cantidad y longitud de las cadenas.

| Fragmento | Secuencia original      | Bases |
|-----------|-------------------------|-------|
| f1        | ATCCGTTGAAGCCGCGGGC     | 19    |
| f2        | TTAACTCGAGG             | 11    |
| f3        | TTAAGTACTGCCCG          | 14    |
| f4        | ATCTGTGTCGGG            | 12    |
| f5        | CGACTCCCACACA           | 14    |
| f6        | CACAGATCCGTTGAAGCCGCGGG | 23    |
| f7        | CTCGAGTTAAGTA           | 13    |
| f8        | CGCGGGCAGTACTT          | 14    |

### Repositorio y archivos

Repositorio: <https://github.com/GinoSebastianD/Molecular>

Carpeta del trabajo: **lab03a-ensamblaje**.

Los archivos **codigos/01\_consenso.cpp** y **codigos/02\_hamiltoniano.cpp** se compilan por separado. La carpeta incluye las entradas, las capturas, los registros de ejecución y este informe. El código usa funciones, cadenas, vectores, bucles y recursión; no contiene comentarios.

# 1 Método y compilación

## Ensamblaje sin errores

Un solapamiento de  $k$  bases existe cuando el sufijo de una cadena coincide exactamente con el prefijo de otra. Para unir las se agrega solamente la parte que no coincide. Por ejemplo, AAAC y ACGT tienen un solapamiento de 2 bases y producen AAACGT.

Para obtener el complemento reverso se invierte la cadena y se cambia A por T, T por A, C por G y G por C. Así, el complemento reverso de AAAAC es GTTTT. El signo + representa la cadena original y el signo - su complemento reverso. Esta consideración de ambas hebras coincide con el modelo de grafos de ensamblaje descrito por Simpson y Durbin [2].

## Programa de consenso

La función buscar prueba cada fragmento pendiente en las dos orientaciones. Si ya está contenido en la cadena construida, lo marca como utilizado. En otro caso, prueba **todos los solapamientos positivos** que coinciden, incluidos los que no son máximos. Cada llamada recursiva agrega un fragmento y después permite volver atrás para probar otra opción.

Al completar los fragmentos, guarda la cadena más corta y la que minimiza  $|longitud - l|$ . Si hay empate en esa distancia, prefiere la cadena más corta; si también empata su longitud, prefiere el mayor enlace mínimo de construcción. Una rama se descarta cuando su longitud supera  $l$  más la mejor diferencia conocida, porque las siguientes uniones no pueden acortarla.

## Compilación de los archivos independientes

Se utilizó g++ 10.3.0 para Windows, el estándar C++11 y las opciones -O2, -Wall, -Wextra y -pedantic. Los dos procesos finalizaron con código de salida 0 y sin advertencias del compilador.

### Compilación de los dos programas C++

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

```
g++.exe (tdm64-1) 10.3.0
Copyright (C) 2020 Free Software Foundation, Inc.
This is free software; see the source for copying conditions. There is NO
warranty; not even for MERCHANTABILITY or FITNESS FOR A PARTICULAR PURPOSE.

> g++ -std=c++11 -O2 -Wall -Wextra -pedantic codigos/01_consenso.cpp -o build/consenso.exe
Codigo de salida: 0

> g++ -std=c++11 -O2 -Wall -Wextra -pedantic codigos/02_hamiltoniano.cpp -o build/hamiltoniano.exe
Codigo de salida: 0
```

Registro real de g++ mostrado en este visor local. Código de salida 0: compilación correcta.

Figura 1. Captura del visor local del registro real de compilación. Los comandos y códigos de salida se conservaron en resultados/compilacion.txt.

La primera línea de entrada de consenso contiene  $n$  y  $l$ . La de hamiltoniano contiene  $n$ ,  $l$  y  $t$ . Después se escriben las  $n$  cadenas, una por línea. Los programas aceptan de 1 a 10 fragmentos con las letras A, C, G y T en mayúsculas. El procedimiento de consenso busca ensamblajes conectados sin huecos; informa si no existe una solución con solapamientos positivos.

## 2 Secuencias de consenso obtenidas

Con  $l = 55$ , el primer programa obtiene una diferencia de 0 bases. Las posiciones de las capturas empiezan en 1 y permiten comprobar dónde aparece cada fragmento. Los guiones indican espacio de alineación, no bases añadidas al ADN.

### Consenso más cercano a 55 bases

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

```
> build/consenso.exe < datos/consenso.txt

CONSENSO SIN ERRORES
Fragmentos: 8
Longitud objetivo: 55 bases
Orientaciones: + directa, - complemento reverso

CONSENSO MAS CERCANO AL OBJETIVO
GCCCGCGGCTTCAACGGATCTGTGTCGGGAGTCGCGGGCAGTACTTAACTCGAGG
Longitud: 55 bases
f1- GCCCGCGGCTTCAACGGAT----- [1, 19]
f2+ -----TTAACTCGAGG [45, 55]
f3- -----CGGGCAGTACTTAA----- [35, 48]
f4+ -----ATCTGTGTCGGG----- [18, 29]
f5- -----TGTGTCGGGAGTCG----- [21, 34]
f6- -CCCGCGGCTTCAACGGATCTGTG----- [2, 24]
f7- -----TACTTAACTCGAG- [42, 54]
f8+ -----CGCGGGCAGTACTT----- [33, 46]
Verificacion exacta: 8/8 fragmentos
Diferencia con el objetivo: 0 bases
Menor enlace de la construccion elegida: 2 bases
```

Salida real de 01\_consensio.cpp. Los signos + y - indican la orientación del fragmento.

Figura 2. Consenso de 55 bases y coincidencia exacta de los ocho fragmentos.

### Consenso más corto encontrado

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

```
CONSENSO MAS CORTO
CCTCGAGTTAAGTACTGCCCGGGCTTCAACGGATCTGTGTCGGGAGTCG
Longitud: 50 bases
f1- -----GCCCGCGGCTTCAACGGAT----- [17, 35]
f2- CCTCGAGTTAA----- [1, 11]
f3+ -----TTAAGTACTGCCCG----- [8, 21]
f4+ -----ATCTGTGTCGGG----- [34, 45]
f5- -----TGTGTCGGGAGTCG [37, 50]
f6- -----CCCGCGGCTTCAACGGATCTGTG----- [18, 40]
f7+ -CCTCGAGTTAAGTA----- [2, 14]
f8- -----AAGTACTGCCCGG----- [10, 23]
Verificacion exacta: 8/8 fragmentos

Estados visitados: 16374
Construcciones completas evaluadas: 1604
Tiempo de busqueda: 19.090 ms

Codigo de salida: 0
```

Continuación de la misma ejecución de 01\_consensio.cpp.

Figura 3. Consenso más corto, de 50 bases, y estadísticas de la misma búsqueda.

La búsqueda visitó 16 374 estados y evaluó 1 604 construcciones completas. Estas construcciones pueden repetir una misma cadena; no representan 1 604 consensos distintos. La longitud mínima encontrada fue 50, mientras que el objetivo de 55 seleccionó una construcción con enlace mínimo de 2 bases.

### 3 Camino hamiltoniano con linkage

El segundo programa calcula el solapamiento máximo entre cada par de fragmentos orientados. Conserva una arista dirigida cuando el solapamiento es al menos  $t$ . La matriz usa 16 vértices orientados, pero la búsqueda marca el fragmento original como visitado: se elige **una sola orientación de cada uno de los ocho fragmentos**. Por tanto, el camino visita los ocho fragmentos, no los 16 vértices orientados.

La búsqueda recursiva prueba los enlaces disponibles sin repetir fragmentos. Entre los caminos completos escoge el ensamblaje más cercano a  $l$ ; si empatan, el más corto. Para el consenso de 55 bases se fija  $t = 2$ , porque ese es el enlace mínimo observado en su construcción.

#### Camino hamiltoniano con $t = 2$

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

```
> build/hamiltoniano.exe < datos/hamiltoniano_t2.txt

CAMINO HAMILTONIANO
Fragmentos: 8
Longitud objetivo: 55 bases
Linkage t: 2
Vertices orientados: 16
Aristas: 40
Caminos completos: 20

Camino: f1- -[18]-> f6- -[7]-> f4+ -[9]-> f5- -[2]-> f8+ -[12]-> f3- -[7]-> f7- -[10]-> f2+

SECUENCIAS ENLAZADAS
f1- GCCCGCGGCTTCAACGGAT----- [1, 19]
f6- -CCCGCGGCTTCAACGGATCTGTG----- [2, 24]
f4+ -----ATCTGTGTCGGG----- [18, 29]
f5- -----TGTGTCGGGAGTCG----- [21, 34]
f8+ -----CGCGGGCAGTACTT----- [33, 46]
f3- -----CGGGCAGTACTTAA----- [35, 48]
f7- -----TACTTAACTCGAG----- [42, 54]
f2+ -----TTAACTCGAGG----- [45, 55]
ADN GCCCGCGGCTTCAACGGATCTGTGTCGGGAGTCGCGGGCAGTACTTAACTCGAGG
Longitud: 55 bases
Diferencia con el objetivo: 0 bases
Verificacion exacta: 8/8 fragmentos

Estados visitados: 967
Tiempo de grafo y busqueda: 0.112 ms
Grafo guardado en grafo.dot

Codigo de salida: 0
```

Salida real de 02\_hamiltoniano.cpp. Las posiciones se cuentan desde 1.

Figura 4. Ejecución completa con  $t = 2$ , camino, pesos, fragmentos enlazados y cadena resultante.

La suma de las longitudes originales es 120. Los enlaces del camino suman  $18 + 7 + 9 + 2 + 12 + 7 + 10 = 65$ . Por ello, la longitud ensamblada es  **$120 - 65 = 55$  bases**. Se evaluaron 20 caminos completos; el conteo incluye las orientaciones complementarias equivalentes.


Cada arista usa el solapamiento máximo de su par, a diferencia del primer programa, que también prueba solapamientos menores. Ambas búsquedas coinciden en la solución de 55 bases para los datos del laboratorio.

## 4 Visualización del subgrafo acíclico

El grafo completo de  $t = 2$  tiene 16 vértices orientados y 40 aristas. La figura muestra el subgrafo inducido por las ocho orientaciones elegidas: conserva 14 aristas. El camino hamiltoniano aparece en azul; los otros siete enlaces aparecen en gris.

### Subgrafo con las ocho orientaciones elegidas

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian



Umbral  $t = 2$  · 8 vértices · 14 aristas · Pesos expresados en bases coincidentes

Generado a partir de grafo.dot. Todas las aristas avanzan de izquierda a derecha; este subgrafo es acíclico. El grafo completo conserva ambas orientaciones: 16 vértices y 40 aristas.

Figura 5. Subgrafo obtenido del archivo grafo.dot, con pesos en bases coincidentes.

En esta disposición todas las aristas avanzan de izquierda a derecha, lo que demuestra que el subgrafo mostrado es acíclico. El camino azul recorre cada fragmento una vez. El grafo completo con ambas orientaciones puede contener ciclos; la figura no afirma que ese grafo completo sea acíclico.

### Elección del umbral y sensibilidad del resultado

El valor  $t = 2$  permite recuperar la longitud solicitada, pero acepta un enlace corto entre  $f5-$  y  $f8+$ . Al elevar el umbral a 7, solo quedan 14 aristas orientadas y dos caminos completos, correspondientes a una cadena de 50 bases y su complemento reverso. Con  $t = 8$  quedan 8 aristas y desaparecen los caminos completos.

| Umbral $t$ | Aristas | Caminos | Longitud obtenida | Diferencia con 55 |
|------------|---------|---------|-------------------|-------------------|
| 2          | 40      | 20      | 55 bases          | 0 bases           |
| 7          | 14      | 2       | 50 bases          | 5 bases           |
| 8          | 8       | 0       | Sin camino        | No corresponde    |

Para  $t = 7$ , los pesos son 10, 7, 12, 7, 18, 7 y 9. Suman 70, de modo que  $120 - 70 = 50$ . El mayor umbral que conserva un camino en estos datos es 7: si con 8 no existe, tampoco existirá con valores superiores, que solo eliminan más aristas.

Acercarse a 55 bases responde al criterio de longitud del enunciado. El ensamblaje de 50 bases tiene enlaces mínimos más largos. Las coincidencias exactas verifican compatibilidad con las lecturas, pero los datos no permiten afirmar una única reconstrucción biológica verdadera.

## 5 Evidencia de los umbrales de enlace

Las siguientes capturas corresponden a ejecuciones independientes del programa hamiltoniano con los mismos ocho fragmentos y  $l = 55$ . En el caso  $t = 7$  se muestran el camino y el alineamiento completos. El caso  $t = 8$  informa correctamente que no existe camino.

### Camino hamiltoniano con $t = 7$

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

```
> build/hamiltoniano.exe < datos/hamiltoniano_t7.txt

CAMINO HAMILTONIANO
Fragmentos: 8
Longitud objetivo: 55 bases
Linkage t: 7
Vertices orientados: 16
Aristas: 14
Camino completo: 2

Camino: f2- -[10]-> f7+ -[7]-> f3+ -[12]-> f8- -[7]-> f1- -[18]-> f6- -[7]-> f4+ -[9]-> f5-

SECUENCIAS ENLAZADAS
f2- CCTCGAGTTAA----- [1, 11]
f7+ -CTCGAGTTAAGTA----- [2, 14]
f3+ -----TTAAGTACTGCCCG----- [8, 21]
f8- -----AAGTACTGCCCGCG----- [10, 23]
f1- -----GCCGCGGCTTCAACGGAT----- [17, 35]
f6- -----CCGCGGCTTCAACGGATCTGTG----- [18, 40]
f4+ -----ATCTGTGTCGGG----- [34, 45]
f5- -----TGTGTCGGGAGTCG [37, 50]
ADN CCTCGAGTTAAGTACTGCCCGGCTTCAACGGATCTGTGTCGGGAGTCG
Longitud: 50 bases
Diferencia con el objetivo: 5 bases
Verificacion exacta: 8/8 fragmentos

Estados visitados: 73
Tiempo de grafo y busqueda: 0.189 ms
Grafo guardado en grafo.dot

Codigo de salida: 0
```

Salida real de 02\_hamiltoniano.cpp. Las posiciones se cuentan desde 1.

Figura 6. Camino de 50 bases con  $t = 7$  y coincidencia exacta de los ocho fragmentos.

### Camino hamiltoniano con $t = 8$

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

```
> build/hamiltoniano.exe < datos/hamiltoniano_t8.txt

CAMINO HAMILTONIANO
Fragmentos: 8
Longitud objetivo: 55 bases
Linkage t: 8
Vertices orientados: 16
Aristas: 8
Camino completo: 0
No existe camino hamiltoniano para este valor de t.

Estados visitados: 25
Tiempo de grafo y busqueda: 0.059 ms
Grafo guardado en grafo.dot

Codigo de salida: 0
```

Salida real de 02\_hamiltoniano.cpp. Las posiciones se cuentan desde 1.

Figura 7. Ausencia de camino al exigir al menos 8 bases por enlace.

## 6 Comportamiento computacional

Se realizaron tres ejecuciones por caso y se tomó la mediana en milisegundos. El tiempo del primer programa mide la búsqueda; el del segundo incluye la construcción de la matriz de solapamientos y la búsqueda. Se excluyen la lectura de entrada, la escritura de resultados y el inicio del proceso.

Para variar  $n$  se usaron 4, 6 y 8 fragmentos de 12 bases, extraídos cada 4 posiciones de una misma cadena generada con semilla 309; se invirtió la orientación de los fragmentos alternos. El objetivo fue  $12 + 4(n - 1)$ , y el grafo usó  $t = 4$ . Las entradas concretas se incluyen en datos/prueba\_n\*.

Para variar la longitud se repitió cada base del conjunto original 1, 2 y 4 veces. Se multiplicaron  $l$  y  $t$  por el mismo factor. Esto es un experimento sintético reproducible: puede introducir solapamientos adicionales y no representa nuevas lecturas biológicas.

### Mediciones con distintas cantidades y longitudes

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

#### COMPORTAMIENTO COMPUTACIONAL

Mediana de 3 ejecuciones por caso, en milisegundos.

| Caso       | Programa     | n | L     | Estados | Mediana ms |
|------------|--------------|---|-------|---------|------------|
| n4_L12     | consenso     | 4 | 12    | 146     | 0.142      |
| n4_L12     | hamiltoniano | 4 | 12    | 47      | 0.032      |
| n6_L12     | consenso     | 6 | 12    | 1602    | 1.172      |
| n6_L12     | hamiltoniano | 6 | 12    | 123     | 0.043      |
| n8_L12     | consenso     | 8 | 12    | 21260   | 16.439     |
| n8_L12     | hamiltoniano | 8 | 12    | 327     | 0.092      |
| oficial_x1 | consenso     | 8 | 11-23 | 16374   | 25.427     |
| oficial_x1 | hamiltoniano | 8 | 11-23 | 967     | 0.192      |
| oficial_x2 | consenso     | 8 | 22-46 | 33511   | 226.116    |
| oficial_x2 | hamiltoniano | 8 | 22-46 | 967     | 1.092      |
| oficial_x4 | consenso     | 8 | 44-92 | 102838  | 1143.666   |
| oficial_x4 | hamiltoniano | 8 | 44-92 | 967     | 1.008      |

Datos obtenidos al ejecutar los programas compilados. Registros completos en la carpeta resultados.

Figura 8. Medianas de tres ejecuciones y estados visitados.  $L$  indica la longitud de los fragmentos o su intervalo.

Con longitud fija de 12 bases, pasar de 4 a 8 fragmentos aumentó los estados del consenso de 146 a 21 260 y la mediana de 0,142 a 16,439 ms. Para el conjunto original ampliado cuatro veces, el consenso visitó 102 838 estados y tardó 1 143,666 ms; con tamaño original visitó 16 374 y tardó 25,427 ms.

El grafo de los casos escalados conservó 967 estados. Sus tiempos fueron menores porque calcula una vez los enlaces y filtra los recorridos con  $t$ . La diferencia no es una comparación de algoritmos equivalentes: el consenso explora más tamaños de solapamiento y aplica una poda distinta. Las duraciones cercanas a un milisegundo pueden variar por la carga del equipo; el número de estados es más estable.

### Complejidad del programa de consenso

Sean  $n$  el número de fragmentos y  $L$  su longitud máxima. Hay  $n!$  órdenes y hasta  $2^n$  elecciones de orientación. Además, el programa puede probar hasta  $L$  tamaños de solapamiento en cada unión. Si  $N$  es el número de estados visitados, una cota conservadora del tiempo es  $O(N n^2 L^2)$ , y  $N$  está acotado por  $O(n! (2L)^n)$ . La memoria auxiliar es  $O(n^2 L)$ , por las cadenas parciales conservadas en la recursión. La poda reduce el trabajo observado, pero no elimina el crecimiento combinatorio del peor caso.

## 7 Complejidad del grafo y verificación

La función solapamiento prueba hasta  $L$  longitudes y compara subcadenas de hasta  $L$  bases. Construir la matriz cuesta  $O(n^2 L^2)$ . La búsqueda puede explorar  $n!$  órdenes y  $2^n$  orientaciones; una cota conservadora de tiempo total es  $O(n^2 L^2 + n \cdot n! \cdot 2^n)$ . La memoria auxiliar es  $O(n^2 + nL)$ , por la matriz, las cadenas y los vectores del recorrido.

El parámetro  $t$  reduce la cantidad de aristas y estados en la práctica. Ninguno de los programas pretende procesar un genoma completo: se trata de búsquedas exhaustivas sencillas para conjuntos pequeños. El límite de entrada de 10 fragmentos evita tamaños accidentales, pero no garantiza una ejecución rápida para cualquier entrada aceptada.

### Verificación del funcionamiento

Laboratorio 03a · Ensamblaje de fragmentos de ADN · Gino Sebastian

#### PRUEBAS DE FUNCIONAMIENTO

- 01. OK Consenso oficial de 55 bases
- 02. OK Hamiltoniano  $t_2$  y enlace de 2 bases
- 03. OK Hamiltoniano  $t_7$  y consenso de 50 bases
- 04. OK Hamiltoniano  $t_8$  sin camino
- 05. OK Solapamiento no maximo para alcanzar 1
- 06. OK Fragmento contenido
- 07. OK Uso obligatorio del complemento reverso
- 08. OK Uso obligatorio del complemento reverso en grafo
- 09. OK Sin solapamientos entre fragmentos
- 10. OK Un fragmento
- 11. OK Letra de ADN invalida
- 12. OK Umbral invalido

Resultado: 12/12 pruebas correctas.

Datos obtenidos al ejecutar los programas compilados. Registros completos en la carpeta resultados.

Figura 9. Resultado de 12 pruebas ejecutadas sobre los programas compilados.

Además de comprobar las salidas esperadas, se verificó por separado que cada fragmento, o su complemento reverso, fuera una subcadena exacta de los consensos oficiales. También se revisaron las coordenadas impresas. El caso AAAA y AAAC, con  $l = 7$ , confirmó que el consenso prueba solapamientos no máximos: obtiene 7 bases, aunque el consenso más corto tiene 5.

### Conclusiones

Los dos códigos resuelven por separado los apartados del laboratorio. El consenso seleccionado alcanza exactamente 55 bases y contiene las ocho lecturas sin errores. El camino con  $t = 2$  reproduce ese resultado y permite visualizar sus enlaces. El análisis de  $t = 7$  y  $t = 8$  muestra cómo un umbral mayor puede llevar a una secuencia más corta o impedir el recorrido. Las pruebas de escala evidencian que la búsqueda crece con el número de fragmentos y con las alternativas de solapamiento.

### Referencias

- [1] Túpac Valdivia, Y. J. (2026). Laboratorio 03a Ensamblaje de Fragmentos de ADN. Biología Molecular Computacional CB309, Universidad Católica San Pablo. Enunciado proporcionado, 16 de septiembre de 2026, pp. 1-2.
- [2] Simpson, J. T., y Durbin, R. (2010). Efficient construction of an assembly string graph using the FM-index. *Bioinformatics*, 26(12), i367-i373. <https://pmc.ncbi.nlm.nih.gov/articles/PMC2881401/>. Se utiliza para el concepto de solapamiento entre hebras opuestas.